Guia de Estudo

Estatística Computacional

Prova baseada nos slides + Listas 1 e 2

Objetivo deste guia. Organizar todo o conteúdo dos quatro conjuntos de slides, destacar o que aparece nas duas listas e separar o que é razoavelmente resolvido **à mão** do que foi desenhado para implementação em R. O foco é permitir refazer as questões manuais sem depender de código.

Base utilizada: Parte 1 - Simulação Estocástica; Parte 2 - Métodos Adicionais de Simulação Estocástica; Integração Numérica; Parte 4 - Métodos de Otimização; Lista 1 (com errata) e Lista 2.

Contents

1 Leitura da prova: o que as listas sugerem **3**

1.1 Classificação das questões da Lista 1 . . . 3

1.2 Classificação das questões da Lista 2 . . . 4

1.3 Prioridade de estudo . . . 4

2 Parte 1 - Simulação Estocástica **6**

2.1 1. Gerar variáveis discretas a partir de $U(0,1)$ . . . 6

2.2 2. Método da transformação inversa . . . 6

2.2.1 Aplicação essencial: Normal truncada em (a,b) . . . 6

2.3 3. Misturas e variáveis latentes . . . 6

2.3.1 Caso-chave da Lista 1: mistura Normal–Gama gera t_ν . . . 7

2.4 4. Método da rejeição . . . 7

2.5 5. Geração de Normais . . . 8

2.5.1 Box–Muller . . . 8

2.5.2 Normal multivariada e Cholesky . . . 8

3 Parte 2 - Métodos adicionais de simulação **9**

3.1 1. SIR - Sampling Importance Resampling . . . 9

3.2 2. Slice Sampler . . . 9

4 Parte 3 - Integração Numérica **10**

4.1 1. Regra do trapézio . . . 10

4.2 2. Regra de Simpson . . . 10

4.3 3. Integração de Monte Carlo . . . 10

4.4 4. Importance sampling . . . 10

4.5 5. Rao–Blackwell . . . 11

4.6 6. Aproximação Gaussiana via Taylor . . . 11

4.6.1 Caso multivariado . . . 11

4.6.2 Exemplo-padrão: Gama(shape a, rate b) . . . 11

4.7 7. Transformação antes da aproximação . . . 12

4.8 8. Método de Laplace . . . 12

5 Parte 4 - Métodos de Otimização **13**

5.1 1. Gradiente . . . 13

5.2 2. Newton–Raphson . . . 13

5.3 3. Regressão logística . . . 13

5.4 4. Regressão logística multinomial . . . 13

5.5 5. Gradientes estocásticos: SGA/SGD . . . 14

5.6 6. Simulated annealing 14
5.7 7. Algoritmo EM 14

6 Roteiros das questões manuais das listas 15
6.1 Lista 1 - Questão 1(a): marginal t_ν 15
6.2 Lista 1 - Questão 2(b): $\mu + Lz \sim N(\mu, \Sigma)$ 15
6.3 Lista 1 - Questão 3(a): Normal truncada 15
6.4 Lista 2 - Questão 2(a): conjugação Poisson–Gama 16
6.5 Lista 2 - Questão 2(b): aproximação Gaussiana 16
6.6 Lista 2 - Questão 3(b): hiperparâmetros 16
6.7 Lista 2 - Questão 3(c): posteriori de (α, β) 17
6.8 Lista 2 - Questão 3(d): gradiente e Hessiana 17

7 Questões computacionais: o que ainda vale saber conceitualmente 18

8 Erros clássicos que custam ponto 18

9 Folha de fórmulas essencial 19

10 Checklist final de estudo 19

Leitura da prova: o que as listas sugerem

Perfil mais provável da parte sem R: a prova tende a ser **teórico-aplicada**, com derivação algébrica e probabilística, construção de algoritmos em pseudocódigo e aplicação de fórmulas. Não parece ser uma prova de demonstrações abstratas longas; quando aparece "mostre que", a demonstração é operacional (marginalização, fatoração de densidade, Jacobiano, derivadas, Taylor).

Nas duas listas, os itens manuais concentram-se em quatro padrões:

- **derivar distribuições**: integrar uma variável latente, obter posteriori, reconhecer família resultante;
- **transformar distribuições**: inversa da acumulada, transformação afim, Jacobiano, Cholesky;
- **aproximar**: Taylor de segunda ordem / aproximação Gaussiana;
- **derivar para otimizar**: gradiente, Hessiana e atualização de Newton-Raphson.

Classificação das questões da Lista 1

Item	O que pede	Classificação	O que estudar para a prova
1(a)	Mostrar que a mistura Normal–Gama gera t_ν	À MÃO	Marginalização; densidades Normal e Gama; integral Gama
1(b)	Pseudocódigo para gerar t_ν	À MÃO	Simulação hierárquica / variável latente
1(c)	Simular 500 valores e comparar histograma	R / COMPUTACIONAL	Contexto apenas
2(a)	Mostrar independência quando D é diagonal	À MÃO	Densidade Normal multivariada e fatoração
2(b)	Mostrar $\mu + Lz \sim N(\mu, \Sigma)$	À MÃO	Transformação afim; Cholesky; Jacobiano
2(c)	Programar gerador e plotar amostra	R / COMPUTACIONAL	Contexto apenas
3(a)	Pseudocódigo para Normal truncada via acumulada	À MÃO	Transformação inversa e CDF truncada
3(b)	Implementar com pnorm/qnorm	R / COMPUTACIONAL	Contexto apenas
3(c)	Simular dois casos e discutir problemas numéricos	R / COMPUTACIONAL	Contexto apenas
4(a)–(c)	SIR, rejeição, histogramas e tempos para NIG	R / COMPUTACIONAL	Estude as fórmulas dos métodos, mas a lista pede implementação
5(a)	Implementar Slice Sampler para Gama	R / COMPUTACIONAL	Algoritmo é conteúdo conceitual

5(b)	Descrever método para encontrar os limites da fatia	**HÍBRIDA**	Vale estudar: raiz numérica / busca dos dois extremos

Interpretação usada aqui: classifiquei pelo verbo do enunciado. "Programar", "simular n valores", "plotar" e comparar tempos foram tratados como computacionais. Pseudocódigo, "mostre que", posteriori, gradiente e Hessiana foram tratados como manuais. O item 5(b) é conceitual, mas nasce de uma implementação; por isso deixei como híbrido.

Classificação das questões da Lista 2

Item	O que pede	Classificação	O que estudar para a prova
1(a)–(d)	Gráfico, trapézio, Monte Carlo, erro-padrão e comparação de propostas	**R / COMPUTACIONAL**	Fórmulas de integração podem ser cobradas, mas o exercício é experimental
2(a)	Posteriori para Poisson com priori Gama	**À MÃO**	Conjugação Poisson–Gama
2(b)	Aproximação Gaussiana da posteriori	**À MÃO**	Moda + segunda derivada da log densidade
3(a)	Simular Gama e fazer histograma	**R / COMPUTACIONAL**	Contexto apenas
3(b)	Determinar a, b a partir de média e variância	**À MÃO**	Momentos da Gama na parametrização shape–rate
3(c)	Obter posteriori conjunta de (α, β)	**À MÃO**	Bayes: verossimilhança $\times$ prioris
3(d)	Gradiente e Hessiana da log posteriori	**À MÃO**	Derivadas; digamma Ψ; trigamma Ψ'
3(e)	Implementar Newton-Raphson e plotar convergência	**R / COMPUTACIONAL**	A atualização de Newton é conteúdo de prova, embora a implementação seja R

Na Lista 2, item 3(e), o texto diz "máximo a posteriori", mas a expressão impressa mostra "arg min". Isso é uma inconsistência interna da própria lista. Para estudar, o ponto importante é: MAP = maximizar a log-posteriori e Newton-Raphson usa gradiente e Hessiana.

Prioridade de estudo

- **PRIORIDADE A**: transformação inversa; mistura/hierarquia; Normal multivariada + Cholesky; Poisson–Gama; aproximação Gaussiana; gradiente/Hessiana; Newton-Raphson.
- **PRIORIDADE B**: rejeição, SIR, Slice Sampler, Monte Carlo/importance sampling, trapézio/Simpson.

- **PRIORIDADE C**: regressão logística/multinomial, SGD/SGA, simulated annealing e EM. Não aparecem diretamente nas questões manuais das listas, mas estão nos slides e portanto continuam no escopo declarado.

Parte 1 - Simulação Estocástica

1. Gerar variáveis discretas a partir de $U(0,1)$

Se $P(X = x_j) = p_j$ e $F_j = \sum_{i=1}^{j} p_i$, divida $(0,1)$ em intervalos

$$I_j = (F_{j-1}, F_j], \qquad F_0 = 0.$$

Gere $U \sim U(0,1)$ e escolha $X = x_j$ quando $U \in I_j$.

Ideia-mãe da disciplina: transformar uma variável fácil de simular (geralmente Uniforme) em uma variável com distribuição difícil.

2. Método da transformação inversa

Se F_X é contínua e inversível e $U \sim U(0,1)$,

$$\boxed{X = F_X^{-1}(U) \sim F_X.}$$

Exemplo dos slides: para $X \sim \text{Exp}(1)$,

$$F(x) = 1 - e^{-x} \quad \Rightarrow \quad X = -\log U.$$

Para $\text{Exp}(b)$ na parametrização taxa,

$$X = -\frac{1}{b}\log U.$$

Se k é inteiro, uma $\text{Gama}(k, b)$ pode ser gerada como soma de k exponenciais de taxa b.

Aplicação essencial: Normal truncada em (a, b)

Se $X \sim N(\mu, \sigma^2)$ antes do truncamento, defina

$$A = \Phi\left(\frac{a-\mu}{\sigma}\right), \qquad B = \Phi\left(\frac{b-\mu}{\sigma}\right).$$

A CDF truncada é

$$F_T(x) = \frac{\Phi((x-\mu)/\sigma) - A}{B - A}, \qquad a < x < b.$$

Logo, com $U \sim U(0,1)$,

$$\boxed{X = \mu + \sigma\,\Phi^{-1}\big(A + U(B - A)\big).}$$

Lista 1, 3(a): o pseudocódigo é exatamente "gerar U; transformar U em uma probabilidade entre A e B; aplicar Φ^{-1}; reescalar por μ, σ".

3. Misturas e variáveis latentes

Se

$$f_X(x) = \sum_k w_k f_k(x), \qquad \sum_k w_k = 1,$$

pode-se gerar uma variável latente $Z \sim \text{Categorical}(w_1, \ldots, w_K)$ e depois gerar

$$X \mid Z = k \sim f_k.$$

A mesma lógica vale para modelos hierárquicos contínuos: primeiro simule o parâmetro latente e depois a variável condicional.

Caso-chave da Lista 1: mistura Normal–Gama gera t_ν

Modelo:

$$X \mid \phi \sim N(0, 1/\phi), \qquad \phi \sim \text{Gama}(\nu/2, \nu/2)$$

(shape–rate). A marginal é

$$p(x) = \int_0^\infty p(x \mid \phi) p(\phi)\, d\phi.$$

Juntando potências e exponenciais,

$$p(x) \propto \int_0^\infty \phi^{(\nu+1)/2-1} \exp\left[-\frac{\nu + x^2}{2}\phi\right] d\phi.$$

Reconheça a integral de um núcleo Gama:

$$\int_0^\infty \phi^{a-1} e^{-b\phi} d\phi = \frac{\Gamma(a)}{b^a}.$$

Isso produz a densidade t_ν.

Pseudocódigo para t_ν:

1. Para $i = 1, \ldots, n$, gere $\phi_i \sim \text{Gama}(\nu/2, \nu/2)$.
2. Gere $X_i \mid \phi_i \sim N(0, 1/\phi_i)$.
3. Retorne $X_1, \ldots, X_n$.

4. Método da rejeição

Queremos amostrar da alvo $p(\theta)$ usando uma proposta fácil $q(\theta)$. Precisamos de

$$0 \le p(\theta) \le A q(\theta) \quad \forall \theta.$$

A menor constante válida é

$$\boxed{A = \max_\theta \frac{p(\theta)}{q(\theta)}.}$$

Algoritmo:

1. gere $\theta^* \sim q$;
2. gere $U \sim U(0, 1)$;
3. aceite se
$$U \le \frac{p(\theta^*)}{A q(\theta^*)};$$
4. repita até obter o tamanho desejado.

Taxa teórica de aceitação:

$$\boxed{P(\text{aceitar}) = \frac{1}{A}.}$$

Quanto mais próximo A estiver de 1, melhor a proposta.

Se a alvo só é conhecida a menos de constante, a constante pode ser absorvida no envelope; o método ainda funciona com o núcleo da densidade.

5. Geração de Normais

Box–Muller

Para $U_1, U_2 \overset{iid}{\sim} U(0,1)$,

$$Z_1 = \sqrt{-2\log U_1}\cos(2\pi U_2), \qquad Z_2 = \sqrt{-2\log U_1}\sin(2\pi U_2)$$

são iid $N(0,1)$.

Normal multivariada e Cholesky

Se $z \sim N(0, I)$ e $\Sigma = LL^\top$, então

$$\boxed{x = \mu + Lz \sim N(\mu, \Sigma).}$$

Pela transformação afim,

$$E(x) = \mu, \qquad \text{Cov}(x) = LIL^\top = \Sigma.$$

Para uma prova por densidades, use

$$z = L^{-1}(x-\mu), \qquad \left|\frac{\partial z}{\partial x}\right| = |L^{-1}|,$$

e note que $|\Sigma| = |L|^2$ e $\Sigma^{-1} = L^{-\top}L^{-1}$.

Lista 1, 2(a): se $D = \text{diag}(\sigma_1^2, \ldots, \sigma_d^2)$, a densidade multivariada fatoriza:

$$f(y) = \prod_{j=1}^{d} \frac{1}{\sqrt{2\pi\sigma_j^2}} \exp\left[-\frac{(y_j-\mu_j)^2}{2\sigma_j^2}\right],$$

logo as componentes são independentes e $Y_j \sim N(\mu_j, \sigma_j^2)$.

Para 2×2, se $\Sigma = \begin{pmatrix} a & c \\ c & b \end{pmatrix}$, uma Cholesky útil à mão é

$$L = \begin{pmatrix} \sqrt{a} & 0 \\ \dfrac{c}{\sqrt{a}} & \sqrt{b - \dfrac{c^2}{a}} \end{pmatrix}.$$

Parte 2 - Métodos adicionais de simulação

1. SIR - Sampling Importance Resampling

Objetivo: aproximar a distribuição alvo $p(\theta)$ sem precisar da constante envelope A da rejeição.

1. Gere candidatos $\theta_1, \ldots, \theta_n \sim q$.
2. Calcule pesos brutos
$$r_i = \frac{p(\theta_i)}{q(\theta_i)}.$$
3. Normalize
$$\boxed{\omega_i = \frac{r_i}{\sum_{j=1}^{n} r_j}.}$$
4. Reamostre dos pontos $\theta_1, \ldots, \theta_n$ com probabilidades ω_i.

Diferença para rejeição: rejeição produz amostras exatas de p (sob as condições do método); SIR produz uma aproximação discreta de p, que melhora quando o número inicial n cresce.

Uma boa proposta q deve cobrir as regiões de massa de p; caso contrário, poucos pesos dominam e a reamostra degenera.

2. Slice Sampler

A ideia é representar $f(x)$ como a marginal de uma uniforme na região abaixo da curva:

$$(X, U) \sim \text{Unif}\{(x, u) : 0 < u < f(x)\}.$$

As condicionais são

$$U \mid X = x \sim U(0, f(x)),$$
$$X \mid U = u \sim \text{Unif}\{x : u < f(x)\}.$$

Algoritmo simplificado dos slides:

1. inicialize x_0;
2. gere $u_1 \sim U(0, f(x_0))$;
3. encontre c_1, c_2 tais que $f(c_1) = f(c_2) = u_1$;
4. gere $x_1 \sim U(c_1, c_2)$;
5. repita.

Lista 1, 5(b): para uma Gama unimodal, há em geral dois pontos da curva com a mesma altura u: um à esquerda e outro à direita da moda. Uma estratégia manual conceitual é procurar a raiz em cada lado da moda usando bisseção ou Newton. O importante é reconhecer que os extremos da "fatia" resolvem $f(x) = u$.

Parte 3 - Integração Numérica

1. Regra do trapézio

Em um intervalo $[a, b]$,

$$\boxed{\int_a^b f(x)dx \approx \frac{b-a}{2}[f(a)+f(b)].}$$

Em uma grade $a = x_0 < \cdots < x_m = b$ com passo h,

$$\boxed{\int_a^b f(x)dx \approx h\left[\frac{f(x_0)+f(x_m)}{2} + \sum_{j=1}^{m-1} f(x_j)\right].}$$

2. Regra de Simpson

Em $[a, b]$, com $m = (a+b)/2$,

$$\boxed{\int_a^b f(x)dx \approx \frac{b-a}{6}\left[f(a)+4f(m)+f(b)\right].}$$

Para Simpson composto, use número par de subintervalos e pesos $1, 4, 2, 4, \ldots, 2, 4, 1$.

3. Integração de Monte Carlo

Escreva

$$I = \int h(x)dx = \int \frac{h(x)}{f(x)} f(x)dx = E_f\left[\frac{h(X)}{f(X)}\right].$$

Se $X_1, \ldots, X_n \overset{iid}{\sim} f$,

$$\boxed{\hat{I} = \frac{1}{n}\sum_{i=1}^{n} \frac{h(X_i)}{f(X_i)}.}$$

Um estimador da variância de $\hat{I}$ usado nos slides é

$$\boxed{v_n = \frac{1}{n^2}\sum_{i=1}^{n}\left(\frac{h(X_i)}{f(X_i)} - \hat{I}\right)^2,}$$

e a aproximação Normal aparece como

$$\frac{\hat{I} - I}{\sqrt{v_n}} \approx N(0, 1).$$

Assim, $\sqrt{v_n}$ é o erro-padrão que entra na padronização.

4. Importance sampling

Para

$$I = \int h(x)p(x)dx,$$

escolha uma proposta q e reescreva

$$I = E_q\left[h(X)\frac{p(X)}{q(X)}\right].$$

Logo,

$$\boxed{\hat{I} = \frac{1}{n}\sum_{i=1}^{n} h(X_i)\frac{p(X_i)}{q(X_i)}, \quad X_i \sim q.}$$

Escolha de q: deve colocar massa onde $h(x)p(x)$ é importante e não pode ser zero onde o integrando é relevante. Em problemas de cauda rara, uma proposta de caudas mais pesadas pode reduzir drasticamente a variância.

5. Rao–Blackwell

Se $\phi(X)$ estima θ, então

$$\mathrm{Var}(E[\phi(X) \mid Y]) \leq \mathrm{Var}(\phi(X)),$$

com o mesmo valor esperado. A ideia é trocar um estimador ruidoso por sua esperança condicional quando essa esperança é calculável.

6. Aproximação Gaussiana via Taylor

Se f é uma densidade univariada com moda interior a e $g(x) = \log f(x)$, então

$$g(x) \approx g(a) + \frac{1}{2}g''(a)(x-a)^2,$$

pois $g'(a) = 0$. Defina

$$\boxed{v = \left[-g''(a)\right]^{-1}.}$$

Então

$$\boxed{X \approx N(a, v).}$$

Regra de ouro para prova:

1. trabalhe com $\log f$ (ou log-posteriori);
2. ache a moda resolvendo primeira derivada $= 0$;
3. avalie a segunda derivada na moda;
4. variância aproximada $= -1/(\text{segunda derivada})$.

Caso multivariado

Se θ^* maximiza $\log f(\theta)$ e H é a Hessiana,

$$\boxed{\theta \approx N_d\left(\theta^*, \left[-H(\theta^*)\right]^{-1}\right).}$$

Exemplo-padrão: Gama(shape a, rate b)

Para $a > 1$,

$$\log f(x) = C + (a-1)\log x - bx.$$

Moda:

$$\boxed{x^* = \frac{a-1}{b}.}$$

Curvatura:

$$\frac{d^2}{dx^2}\log f(x) = -\frac{a-1}{x^2}.$$

Logo

$$\boxed{X \approx N\left(\frac{a-1}{b}, \frac{a-1}{b^2}\right).}$$

7. Transformação antes da aproximação

Se a variável tem suporte positivo, aproximar diretamente por Normal pode atribuir probabilidade a valores negativos. Os slides sugerem transformar $\eta = \log\theta$, aproximar η por Normal e voltar para $\theta = e^{\eta}$, resultando em uma aproximação lognormal.

8. Método de Laplace

Para aproximar uma razão de integrais

$$I = \frac{\int g(\theta)p(y \mid \theta)\pi(\theta)d\theta}{\int p(y \mid \theta)\pi(\theta)d\theta},$$

defina

$$L_1(\theta) = \log p(y \mid \theta) + \log \pi(\theta),$$
$$L_2(\theta) = \log g(\theta) + \log p(y \mid \theta) + \log \pi(\theta).$$

Se m_i maximiza L_i e

$$v_i^2 = [-L_i''(m_i)]^{-1},$$

então

$$\boxed{I \approx \exp\{L_2(m_2) - L_1(m_1)\}\left(\frac{v_2^2}{v_1^2}\right)^{1/2}.}$$

No caso multivariado, substitua a razão das variâncias pela razão dos determinantes das matrizes de covariância aproximadas.

Parte 4 - Métodos de Otimização

1. Gradiente

Para maximizar $f(\theta)$,

$$\boxed{\theta^{(t+1)} = \theta^{(t)} + \alpha \nabla f(\theta^{(t)}).}$$

Para minimizar,

$$\boxed{\theta^{(t+1)} = \theta^{(t)} - \alpha \nabla f(\theta^{(t)}).}$$

O gradiente aponta na direção de maior crescimento e é perpendicular às curvas de nível.

2. Newton–Raphson

Com Hessiana

$$H(\theta) = \frac{\partial^2 f(\theta)}{\partial \theta \partial \theta^\top},$$

a expansão de Taylor do gradiente produz

$$\boxed{\theta^{(t+1)} = \theta^{(t)} - H(\theta^{(t)})^{-1} \nabla f(\theta^{(t)}).}$$

Para matriz 2×2,

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}, \quad ad - bc \neq 0.$$

Isto é especialmente útil em Newton-Raphson com dois parâmetros.

3. Regressão logística

Para $Y_i \sim$ Bernoulli(p_i),

$$p_i = \sigma(x_i^\top \beta), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Log-verossimilhança:

$$\ell(\beta) = \sum_i \left[y_i x_i^\top \beta - \log(1 + e^{x_i^\top \beta}) \right].$$

Gradiente:

$$\boxed{\nabla_\beta \ell(\beta) = X^\top (y - \sigma(X\beta)).}$$

A informação de Fisher é

$$I(\beta) = X^\top W X,$$

com $W_{ii} = p_i(1 - p_i)$.

4. Regressão logística multinomial

Com classe-base 0, para $k = 1, \ldots, K$,

$$P(Y_i = k \mid x_i) = \frac{e^{x_i^\top \beta_k}}{1 + \sum_{\ell=1}^{K} e^{x_i^\top \beta_\ell}}.$$

Gradiente por classe:

$$\boxed{\nabla_{\beta_k} \ell = \sum_i x_i \left[1(Y_i = k) - P(Y_i = k \mid x_i) \right].}$$

5. Gradientes estocásticos: SGA/SGD

Em vez de usar todas as observações, use um minibatch B. Para maximizar log-verossimilhança (SGA):

$$\theta^{(t+1)} = \theta^{(t)} + \gamma \widehat{\nabla \ell}_B.$$

Para minimizar a log-verossimilhança negativa (SGD):

$$\theta^{(t+1)} = \theta^{(t)} - \gamma \widehat{\nabla(-\ell)}_B.$$

Taxa grande: passos rápidos, mas pode oscilar/passsar do ótimo. Taxa pequena: estável, porém lenta. Os slides citam condições de Robbins–Monro para taxas dinâmicas:

$$\sum_{t=1}^{\infty} \gamma_t = \infty, \qquad \sum_{t=1}^{\infty} \gamma_t^2 < \infty.$$

6. Simulated annealing

Para maximizar $f(x)$, defina uma densidade artificial

$$g_T(x) \propto \exp\left(\frac{f(x)}{T}\right).$$

Proponha um novo ponto próximo do atual e aceite com probabilidade

$$\boxed{\min\left\{1, \frac{g_T(x_{prop})}{g_T(x_{atual})}\right\}.}$$

Temperatura alta achata a paisagem e facilita escapar de máximos locais; reduza T progressivamente para concentrar perto do máximo global.

7. Algoritmo EM

Usado quando há variável latente/faltante z e a verossimilhança completa é mais simples que a marginal.

1. **E-step:**
$$Q(\theta \mid \theta^{(j)}) = E_{Z|X,\theta^{(j)}}[\log p(X, Z \mid \theta)].$$
2. **M-step:**
$$\boxed{\theta^{(j+1)} = \arg\max_{\theta} Q(\theta \mid \theta^{(j)}).}$$

Para mistura de Normais, o E-step calcula “responsabilidades”

$$p_{ik}^{(j)} = P(Z_i = k \mid x_i, \theta^{(j)}) = \frac{w_k^{(j)} N(x_i \mid \mu_k^{(j)}, \sigma_k^{2(j)})}{\sum_\ell w_\ell^{(j)} N(x_i \mid \mu_\ell^{(j)}, \sigma_\ell^{2(j)})}.$$

O M-step atualiza médias, variâncias e pesos por médias ponderadas dessas responsabilidades.

Roteiros das questões manuais das listas

Lista 1 - Questão 1(a): marginal t_ν

Roteiro de resolução

1. Escreva $p(x) = \int_0^\infty p(x \mid \phi)p(\phi)d\phi$.
2. Substitua a Normal de variância $1/\phi$:

$$p(x \mid \phi) = \sqrt{\frac{\phi}{2\pi}} e^{-\phi x^2/2}.$$

3. Substitua a Gama(shape $\nu/2$, rate $\nu/2$).
4. Junte as potências de ϕ e os termos exponenciais.
5. Reconheça o núcleo Gama com shape $(\nu+1)/2$ e rate $(\nu+x^2)/2$.
6. Use a integral Gama e simplifique até a densidade t_ν.

Lista 1 - Questão 2(b): $\mu + Lz \sim N(\mu, \Sigma)$

Duas rotas válidas:

Rota curta por transformação afim:

$$E(\mu + Lz) = \mu, \quad \text{Cov}(\mu + Lz) = LIL^\top = LL^\top = \Sigma.$$

Como transformação linear de Normal continua Normal, conclui-se o resultado.

Rota pedida pelo enunciado (Jacobiano):

$$x = \mu + Lz \iff z = L^{-1}(x - \mu).$$

Então

$$f_X(x) = f_Z(L^{-1}(x-\mu))|L^{-1}|,$$

e a forma do expoente vira

$$(x-\mu)^\top L^{-\top} L^{-1}(x-\mu) = (x-\mu)^\top \Sigma^{-1}(x-\mu).$$

Além disso $|L^{-1}| = |\Sigma|^{-1/2}$.

Lista 1 - Questão 3(a): Normal truncada

Pseudocódigo que vale decorar

1. Calcule $A = \Phi((a-\mu)/\sigma)$ e $B = \Phi((b-\mu)/\sigma)$.
2. Para $i = 1, \ldots, n$:
   (a) gere $U_i \sim U(0,1)$;
   (b) $V_i = A + U_i(B - A)$;
   (c) $X_i = \mu + \sigma\Phi^{-1}(V_i)$.
3. Retorne $X_1, \ldots, X_n$.

Lista 2 - Questão 2(a): conjugação Poisson–Gama

Modelo:

$$y_i \mid \lambda \overset{iid}{\sim} \text{Poisson}(\lambda), \qquad \lambda \sim \text{Gama}(a, b)$$

(shape–rate). O núcleo da verossimilhança é

$$L(\lambda) \propto \lambda^{\sum_i y_i} e^{-n\lambda}.$$

A priori tem núcleo

$$\pi(\lambda) \propto \lambda^{a-1} e^{-b\lambda}.$$

Portanto

$$\boxed{\lambda \mid y \sim \text{Gama}\left(a + \sum_i y_i,\ b + n\right).}$$

Para os números da lista: $\sum y_i = 14$, $a = b = 1$, então

$$\boxed{\lambda \mid y \sim \text{Gama}(15, 6).}$$

Lista 2 - Questão 2(b): aproximação Gaussiana

Para Gama(a^*, b^*),

$$\boxed{N\left(\frac{a^* - 1}{b^*}, \frac{a^* - 1}{(b^*)^2}\right)}$$

é a aproximação de Taylor apresentada nos slides.

Com $a^* = 15$ e $b^* = 6$:

$$\boxed{\text{média da aproximação} = \frac{14}{6} = \frac{7}{3},} \qquad \boxed{\text{variância} = \frac{14}{36} = \frac{7}{18}.}$$

Não confunda com a média e variância *exatas* da Gama. A aproximação Gaussiana do slide é centrada na **moda**, não na média exata.

Lista 2 - Questão 3(b): hiperparâmetros

Na parametrização Gama(shape a, rate b),

$$E(X) = \frac{a}{b}, \qquad \text{Var}(X) = \frac{a}{b^2}.$$

Queremos $E = 1$ e Var $= 10$:

$$\frac{a}{b} = 1 \Rightarrow a = b, \qquad \frac{a}{b^2} = 10 \Rightarrow \frac{1}{b} = 10.$$

Logo

$$\boxed{a = b = 0.1.}$$

Lista 2 - Questão 3(c): posteriori de (α, β)

Use Gama(shape α, rate β):

$$f(y_i \mid \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} y_i^{\alpha-1} e^{-\beta y_i}.$$

A verossimilhança é

$$L(\alpha, \beta) \propto \frac{\beta^{n\alpha}}{\Gamma(\alpha)^n} \left(\prod_{i=1}^{n} y_i \right)^{\alpha-1} \exp\left(-\beta \sum_i y_i \right).$$

Com prioris independentes $\alpha \sim$ Gama(a, b) e $\beta \sim$ Gama(a, b),

$$\pi(\alpha, \beta) \propto \alpha^{a-1} e^{-b\alpha}\, \beta^{a-1} e^{-b\beta}.$$

Portanto, a posteriori a menos da constante é

$$\boxed{p(\alpha, \beta \mid y) \propto \frac{\beta^{n\alpha+a-1}}{\Gamma(\alpha)^n} \left(\prod_i y_i \right)^{\alpha-1} \alpha^{a-1} \exp\left[-\beta \sum_i y_i - b\alpha - b\beta \right].}$$

Lista 2 - Questão 3(d): gradiente e Hessiana

Trabalhe com a log-posteriori:

$$\ell(\alpha, \beta) = n\alpha \log \beta - n \log \Gamma(\alpha) + (\alpha - 1) \sum_i \log y_i - \beta \sum_i y_i + (a-1) \log \alpha - b\alpha + (a-1) \log \beta - b\beta + C.$$

Use

$$\frac{d}{d\alpha} \log \Gamma(\alpha) = \Psi(\alpha), \qquad \frac{d}{d\alpha} \Psi(\alpha) = \Psi'(\alpha).$$

Gradiente:

$$\boxed{\frac{\partial \ell}{\partial \alpha} = n \log \beta - n\Psi(\alpha) + \sum_i \log y_i + \frac{a-1}{\alpha} - b}$$

$$\boxed{\frac{\partial \ell}{\partial \beta} = \frac{n\alpha}{\beta} - \sum_i y_i + \frac{a-1}{\beta} - b}$$

Hessiana:

$$\boxed{H(\alpha, \beta) = \begin{pmatrix} -n\Psi'(\alpha) - \dfrac{a-1}{\alpha^2} & \dfrac{n}{\beta} \\ \dfrac{n}{\beta} & -\dfrac{n\alpha + a - 1}{\beta^2} \end{pmatrix}.}$$

Mesmo que o item 3(e) seja R, a atualização manual que conecta 3(d) a Newton é

$$\begin{pmatrix} \alpha \\ \beta \end{pmatrix}_{t+1} = \begin{pmatrix} \alpha \\ \beta \end{pmatrix}_t - H(\alpha_t, \beta_t)^{-1} \nabla \ell(\alpha_t, \beta_t).$$

Questões computacionais: o que ainda vale saber conceitualmente

Mesmo que não entrem diretamente por dependerem de R, elas indicam o tipo de raciocínio que o professor valoriza.

Questão	Método	Conceito que vale reter
Lista 1, 1(c)	Mistura/hierarquia	Simulação valida uma representação teórica da t
Lista 1, 2(c)	Cholesky	$x = \mu + Lz$ é o gerador da Normal multivariada
Lista 1, 4	SIR vs rejeição	SIR usa pesos normalizados; rejeição usa envelope A e taxa $1/A$
Lista 1, 5	Slice Sampler	Alternar $U \mid X$ e $X \mid U$ para amostrar sob a curva
Lista 2, 1	Integração	Comparar viés/erro numérico e variância Monte Carlo; importância depende da proposta
Lista 2, 3(e)	Newton-Raphson	Curvatura (Hessiana) determina direção e tamanho do passo

Erros clássicos que custam ponto

- **Gama:** confirme sempre se o segundo parâmetro é taxa ou escala. Nos slides/listas relevantes, a forma usada é compatível com taxa: $E = a/b$, Var $= a/b^2$.
- **Aproximação Gaussiana:** centro = moda da log-densidade, não necessariamente a média exata da distribuição.
- **Newton:** a fórmula tem $-H^{-1}\nabla f$ tanto para achar raiz do gradiente em máximo quanto em mínimo; o tipo de ponto depende da curvatura.
- **Rejeição:** o envelope exige $p \leq Aq$ em todo o suporte relevante. Se $q = 0$ onde $p > 0$, o método falha.
- **SIR:** normalizar os pesos é obrigatório para reamostrar.
- **Transformação inversa truncada:** não use diretamente $\Phi^{-1}(U)$; primeiro remapeie U para o intervalo de probabilidades $[A, B]$.
- **Normal multivariada:** matriz diagonal implica independência para a Normal; covariância zero não implica independência para distribuições arbitrárias.
- **Hessiana:** os termos cruzados devem coincidir ($H_{12} = H_{21}$) quando as condições usuais de regularidade valem.

Folha de fórmulas essencial

Simulação

Inversa:

$$X = F^{-1}(U),\ U \sim U(0,1).$$

Rejeição:

$$A = \max \frac{p}{q}, \quad P(\text{aceitar} \mid \theta) = \frac{p(\theta)}{Aq(\theta)}, \quad P(\text{aceitar}) = 1/A.$$

SIR:

$$\omega_i = \frac{p(\theta_i)/q(\theta_i)}{\sum_j p(\theta_j)/q(\theta_j)}.$$

Box–Muller:

$$Z_1 = \sqrt{-2\log U_1}\cos(2\pi U_2).$$
$$Z_2 = \sqrt{-2\log U_1}\sin(2\pi U_2).$$

Normal multivariada:

$$x = \mu + Lz, \quad LL^\top = \Sigma.$$

Integração

Trapézio:

$$\frac{b-a}{2}[f(a)+f(b)].$$

Simpson:

$$\frac{b-a}{6}\left[f(a)+4f\left(\frac{a+b}{2}\right)+f(b)\right].$$

MC:

$$\hat{I} = \frac{1}{n}\sum \frac{h(X_i)}{f(X_i)}.$$

Importance:

$$\hat{I} = \frac{1}{n}\sum h(X_i)\frac{p(X_i)}{q(X_i)}.$$

Aproximações

Gaussiana 1D:

$$x^* = \arg\max \log f(x),$$

$$v = [-\ell''(x^*)]^{-1}, \quad X \approx N(x^*, v).$$

Gaussiana multivariada:

$$\theta \approx N_d(\theta^*, [-H(\theta^*)]^{-1}).$$

Gama (a,b):

$$\text{moda} = \frac{a-1}{b}, \quad v_{Taylor} = \frac{a-1}{b^2}.$$

Otimização

Gradiente ascendente:

$$\theta_{t+1} = \theta_t + \alpha\nabla f(\theta_t).$$

Newton:

$$\theta_{t+1} = \theta_t - H(\theta_t)^{-1}\nabla f(\theta_t).$$

EM:

$$Q(\theta \mid \theta^{(j)}) = E[\log p(X, Z \mid \theta) \mid X, \theta^{(j)}],$$

$$\theta^{(j+1)} = \arg\max Q.$$

Checklist final de estudo

Marque quando conseguir fazer sem consultar o material:

- ☐ Derivar a t_ν a partir do modelo Normal–Gama.
- ☐ Escrever pseudocódigo de simulação hierárquica.
- ☐ Provar independência de componentes Normais quando a covariância é diagonal.
- ☐ Provar $\mu + Lz \sim N(\mu, \Sigma)$ e explicar Cholesky.
- ☐ Escrever o algoritmo da Normal truncada por inversão.
- ☐ Explicar rejeição, A, probabilidade de aceitação e taxa $1/A$.

☐ Explicar SIR e normalizar pesos.

☐ Explicar o Slice Sampler e a variável auxiliar.

☐ Aplicar trapézio, Simpson, Monte Carlo e importance sampling em notação.

☐ Encontrar moda + curvatura para aproximação Gaussiana.

☐ Fazer Poisson–Gama por Bayes sem olhar fórmula.

☐ Derivar log-posteriori, gradiente e Hessiana da Gama(α, β).

☐ Aplicar uma iteração de Newton em 1D ou 2D.

☐ Explicar em palavras SGD/SGA, simulated annealing e EM.

Ordem recomendada na véspera: (1) roteiros das questões manuais; (2) folha de fórmulas; (3) erros clássicos; (4) tópicos de prioridade C apenas depois de dominar os itens de lista.

Referências internas do material: Lista 1; Lista 2; slides de Simulação Estocástica, Métodos Adicionais, Integração Numérica e Métodos de Otimização, todos fornecidos pelo aluno.